

PARTIE 1 : Étude théorique de l'outil Biopython

1. Présentation générale de l'outil

Biopython est l'un des projets les plus emblématiques du mouvement "Bio projects" (incluant BioPerl, BioJava, etc.). Il s'agit d'une collection d'outils Python non commerciaux, développée par une communauté internationale, visant à répondre aux besoins de la bioinformatique et de la biologie computationnelle. Lancé à la fin des années 90, il repose sur le langage Python, réputé pour sa lisibilité et sa puissance. Son but est de fournir des bibliothèques réutilisables pour traiter les données biologiques complexes.

2. Fonctionnalités principales

Biopython offre une vaste gamme de fonctionnalités pour manipuler les données biologiques :

- Manipulation avancée des séquences biologiques :**

Biopython propose un système sophistiqué de manipulation des séquences à travers les classes Seq et SeqRecord. Contrairement aux simples chaînes de caractères, ces objets intègrent nativement la sémantique biologique :

Objets Seq : Représentent des séquences biologiques (ADN, ARN, protéines) avec des méthodes spécialisées pour la transcription inverse (`reverse_complement()`), la traduction (`translate()`), et la recherche de motifs. La gestion automatique des alphabets biologiques évite les erreurs courantes comme la transcription d'une séquence protéique.

Objets SeqRecord : Structure complexe associant une séquence à des métadonnées riches : identifiants, descriptions, annotations, caractéristiques (features), et références. Cette structure est essentielle pour maintenir l'intégrité des données tout au long des pipelines d'analyse.

Système d'annotations : Support complet des formats d'annotation standards (GenBank, EMBL, Swiss-Prot) avec possibilité d'extraire des régions codantes, des sites de restriction, des domaines protéiques, etc.

- Accès programmatique aux bases de données biologiques:**

Biopython intègre des interfaces élaborées pour interroger les principales bases de données biologiques :

Module Entrez : Interface avec le système E-utilities du NCBI permettant des requêtes complexes sur PubMed, GenBank, GEO, et autres bases. Fonctionnalités avancées incluant la gestion des limites de requêtes, le parsing automatique des résultats, et le téléchargement par lots.

Interface avec UniProt : Accès programmatique à la base de données de protéines via l'API REST, avec support des formats UniProtKB, XML, et tabulés.

Accès au Protein Data Bank (PDB) : Téléchargement et parsing des fichiers de structures 3D avec reconstruction des modèles atomiques et extraction des informations cristallographiques.

- **Lecture/Écriture de fichiers** : Support de formats standards tels que FASTA, GenBank, BLAST, ClustalW et Phylip via les modules Bio.SeqIO et Bio.AlignIO.

- **Bioinformatique structurale :**

Module PDB : Lecture, écriture et manipulation des fichiers PDB avec reconstruction des chaînes, résidus, et atomes. Calculs géométriques avancés : distances interatomiques, angles dièdres, rayons de giration.

Analyse des surfaces : Calcul des surfaces accessibles au solvant (SASA), détection des poches hydrophobes, et analyse des interfaces protéine-protéine.

Visualisation : Intégration avec PyMOL et NGL Viewer pour la visualisation interactive des structures.

- **Outils statistiques** : Intégration de modèles de Markov cachés (HMM) et de calculs de fréquences de codons.

3. Aspects techniques

Biopython est une bibliothèque **open-source** distribuée sous la licence "Biopython License Agreement". Écrit principalement en Python avec certaines parties en C pour optimiser les performances de calcul. **L'installation** : Se fait généralement via le gestionnaire de paquets pip (pip install biopython).

```
C:\Users\DELL>pip install biopython
WARNING: Ignoring invalid distribution ~ip (C:\Python312\Lib\site-packages)
WARNING: Ignoring invalid distribution ~ip (C:\Python312\Lib\site-packages)
Collecting biopython
  Downloading biopython-1.86-cp312-cp312-win_amd64.whl.metadata (13 kB)
Requirement already satisfied: numpy in c:\python312\lib\site-packages (from biopython) (1.26.4)
  Downloading biopython-1.86-cp312-cp312-win_amd64.whl (2.7 MB)
                                                 2.7/2.7 MB 6.3 MB/s  0:00:00
WARNING: Ignoring invalid distribution ~ip (C:\Python312\Lib\site-packages)
Installing collected packages: biopython
WARNING: Ignoring invalid distribution ~ip (C:\Python312\Lib\site-packages)
Successfully installed biopython-1.86

[notice] A new release of pip is available: 25.3 -> 26.0.1
[notice] To update, run: python.exe -m pip install --upgrade pip

C:\Users\DELL>
```

Organisé en sous-modules indépendants, permettant à l'utilisateur de n'importer que les composants nécessaires à son analyse.

Biopython ↓
→ Bio : Package principal
→ SeqIO : Entrée/sortie des séquences
→ Align : Alignements de séquences
→ PDB : Structures 3D
→ Phylo : Phylogénie
→ PopGen : Génétique des populations

- Entrez : Accès NCBI
- ExPASy: Accès ExPASy/Swiss-Prot
- Cluster : Analyses de clustering
- Statistics : Statistiques bioinformatiques
- ... 30+ modules supplémentaires

Chaque module est indépendant mais conçu pour une interopérabilité maximale, suivant les principes de cohésion forte et de couplage faible.

4. Points forts

- En tant que logiciel libre, il permet une recherche reproductible sans coût de licence.
- Il sert de "colle" entre différents outils bioinformatiques, permettant d'automatiser des flux de travail complexes.
- Bénéficie d'un "Tutorial and Cookbook" extrêmement riche et d'une communauté active.
- La syntaxe Python rend l'outil accessible aux biologistes n'ayant pas une formation poussée en informatique.

5. Limites et points faibles

- Pour des calculs de très haute intensité sur des données génomiques massives, Python peut être plus lent que des outils compilés en C++ ou Rust.
- Certains modules nécessitent l'installation préalable d'outils externes (comme BLAST ou ClustalW) sur le système.
- Bien que plus simple que d'autres langages, une base en programmation Python reste indispensable.

Références

- Cock, P. J., et al. (2009). Biopython: freely available Python tools for computational molecular biology and bioinformatics. *Bioinformatics*, 25(11), 1422-1423.
- Documentation officielle : Biopython Project
<https://biopython.org/wiki/Documentation>
- Chapman, B., & Chang, J. (2000). Biopython: Python tools for the life sciences. ACM SIGBIO Newsletter.
- Python Software Foundation. (2024). Python for Scientific Computing. Disponible sur : <https://www.python.org/about/success/biopython/>

PARTIE 2 : Étude pratique - Exploration de Zenodo

1. Présentation de Zenodo

Zenodo est une initiative stratégique née d'une collaboration entre le **CERN** (**Organisation européenne pour la recherche nucléaire**) et le projet **OpenAIRE** (**Open Access Infrastructure for Research in Europe**). Lancé officiellement en 2013, Zenodo répond à un besoin critique identifié par la communauté scientifique européenne : la préservation à long terme et le partage ouvert de tous les produits de la recherche, au-delà des seules publications traditionnelles.

- **Objectifs :**

1. Garantie de conservation des données pour plusieurs décennies, avec des stratégies de réPLICATION sur multiples sites géographiques.
2. Accès ouvert par défaut, avec options de restriction temporaire justifiées (embargos).
3. Conformité avec les standards internationaux (OAI-PMH, REST API, [Schema.org](#)).
4. Attribution de DOI (Digital Object Identifier) pérennes permettant la traçabilité des citations.
5. Connexion avec ORCID, GitHub, RID, et autres systèmes d'identité numérique des chercheurs.

- **Types de contenus hébergés**

Il héberge des jeux de données (datasets), des logiciels, des publications, des posters, des présentations et même des images ou vidéos.

Catégorie	Exemples spécifiques	Formats acceptés	Taille maximale
Publications	Prépublications, articles, chapitres, thèses	PDF, DOCX, LaTeX	50 GB/dépôt
Données de recherche	Jeux de données bruts, données dérivées	CSV, JSON, HDF5, NetCDF	50 GB/dépôt
Logiciels et code	Scripts, packages, notebooks Jupyter	Python, R, Julia, Dockerfiles	50 GB/dépôt
Matériels pédagogiques	Supports de cours, exercices, tutoriels	PPTX, Markdown, SCORM	50 GB/dépôt
Produits multimédia	Vidéos, images, enregistrements audio	MP4, TIFF, WAV, PNG	50 GB/dépôt
Produits de vulgarisation	Blogs scientifiques, infographies	HTML, SVG, PSD	50 GB/dépôt
Autres produits	Posters, présentations, rapports techniques	PDF, PPTX, Keynote	50 GB/dépôt

- **Intérêt stratégique pour les sciences de la nature et de la vie**

Pour la recherche fondamentale :

1. Archivage des données brutes permettant la vérification indépendante des résultats.
2. Réduction du "file drawer problem" (biais de publication).
3. Support des standards spécifiques (Darwin Core pour la biodiversité, MIAME pour la transcriptomique).

Pour la recherche appliquée :

1. Réutilisation des données par d'autres équipes évitant la duplication d'efforts.
2. Agrégation de jeux de données similaires pour augmenter la puissance statistique.
3. Comparaison inter-laboratoires des résultats expérimentaux.


Pour les étudiants :

1. Accès à des données réelles pour les travaux pratiques.
2. Développement de compétences en gestion et partage des données (FAIR principles).
3. Possibilité de déposer des mémoires, thèses, et données de projets.

2. Description des étapes réalisées

Étape 1 : Visite et Navigation

Dans cette étape, nous avons tout d'abord fais une **Inscription** sur la plateforme <https://zenodo.org/>, avec la sélection GitHub pour l'intégration future avec les dépôts de code.



Après l'inscription on a fait Complétion du profil :

Profile

Username
Warda
Required. Username must start with a letter, be at least three characters long and only contain alphanumeric characters, dashes and underscores.

Full name
Université de Jijel, Faculté des Sciences de la Nature et de la Vie

Affiliations
Biological Sciences → Bioinformatics

Email address

Re-enter email address

Please re-enter your email address.

Cancel **Update profile**

This site uses cookies. Find out more on [how we use cookies](#) **Accept all cookies**

Sur <https://zenodo.org/>. L'interface présente une barre de recherche centrale et des options de filtrage sur la gauche (type de document, accès, année).

zenodo

Search records... Communities My dashboard

Featured communities

EU Open Research Repository

Browse

Recent uploads

February 6, 2026 (v2) Software Open

Data for beta diversity analysis of insect herbivory evolution

Xiao, Lifang; Chen, Liang; Ren, Dong

Why use Zenodo?

- Safe — Your research is stored safely for the future in CERN's Data Centre for as long as CERN exists
- Trusted — Built and operated by CERN and the scientific community

Étape 2 : Recherche stratégique de datasets pertinents

Objectif : Trouver un dataset répondant aux critères suivants :

- Pertinence thématique** : Sciences de la vie, biologie moléculaire, génomique
- Seulement les contenus en accès libre**

Saisissez la requête dans la barre de recherche. L'utilisation de guillemets permet de chercher l'expression exacte et le mot-clé "genome" cible le domaine demandé

Requête principale utilisée :

genome AND "Homo sapiens" AND type:dataset AND access_right:open

zenodo | genome AND "Homo sapiens" | Communities | My dashboard

60 result(s) found

Sort by Best match

Versions

December 27, 2021 (v1) Dataset Open

Additional data for manuscript "Alevin-fry unlocks rapid, accurate, and memory-frugal quantification of single-cell RNA-seq data"
He,Dongze; Zakeri,Mohsen; Sarkar,Hirak; and 3 others

Additional data for manuscript "Alevin-fry unlocks rapid, accurate, and memory-frugal quantification of single-cell RNA-seq data" Additional mitochondrial gene sequences for Danio rerio, Homo sapiens, and Mus musculus.

Open 51 Restricted 9

Uploaded on December 28, 2021

November 4, 2021 (v1) Dataset Open

Reference-Sim
Lucia Williams

Splice graphs constructed by superimposing transcripts from the positive strand in the GRCh 104 homo sapiens reference genome with abundances sampled from the lognormal distribution with mean and variance both equal to -4, and then multiplied by 1000 and rounded to the nearest integer. Transcripts rounded to 0 are excluded. See https://github.com/lgv2/create_transcript_data for code to create.

Dataset 60

Uploaded on November 5, 2021

May 5, 2015 (v1) Dataset Open

Data from: The translational landscape of the splicing factor SRSF1 and its role in mitosis
Maslom, Magdalena M.; Heras, Sara R.; Bellora, Nicolas; and 2 others

The shuttling Serine/Arginine rich (SR) protein SRSF1 (previously known as SF2/ASF) is a splicing regulator that also activates translation in the cytoplasm. In order to dissect the gene network that is translationally regulated by SRSF1, we performed a high-throughput deep sequencing analysis of polysomal fractions in cells overexpressing SRSF1. We identified approximately 1,500 mRNAs that are...
Part of Dryad
Uploaded on June 14, 2021

Dataset 2

September 23, 2015 (v1) Dataset Open

Data from: Genomic DNA transposition induced by human PGBD5
Henssen, Anton G.; Henaff, Elizabeth; Jiang, Eileen; and 10 others

Transposons are mobile genetic elements that are found in nearly all organisms, including humans. Mobilization of DNA transposons by transposase enzymes can cause genomic rearrangements, but our knowledge of human genes derived from transposases is limited. In this study, we find that the protein encoded by human PGBD5, the most evolutionarily conserved transposable element-derived gene in...
Part of Dryad
Uploaded on June 16, 2021

Dataset 1

September 2, 2022 (1.1) Dataset Open

Host removal database: Homo sapiens, Sars-CoV-2, PhiX174

File type

TXT 15 ZIP 14

Étape 3 : Sélection et Critères

Filtres appliqués dans l'interface graphique :

1. **Resource Type** : Dataset (sélectionné)
2. **File Type** : FASTA, FASTQ (sélectionnés)
3. **Access Right** : Open Access (sélectionné)
4. **Sujet** : "Homo sapiens" (sélectionnées)

zenodo | genome AND "Homo sapiens" | Communities | My dashboard

1 result(s) found

Sort by Best match

Versions

September 28, 2015 (v1) Dataset Open

Data from: Genomic DNA transposition induced by human PGBD5
Henssen, Anton G.; Henaff, Elizabeth; Jiang, Eileen; and 10 others

Transposons are mobile genetic elements that are found in nearly all organisms, including humans. Mobilization of DNA transposons by transposase enzymes can cause genomic rearrangements, but our knowledge of human genes derived from transposases is limited. In this stu...
Part of Dryad
Uploaded on June 16, 2021

Access status

Open 51 Restricted 9

Resource types

Dataset 60

Subjects

Homo Sapiens 30

(1) 10 results per page

Étape 4 : Téléchargement et Récupération des métadonnées

Une fois sur la page du dataset, on a cliqué sur le bouton "Download" en bas de page. Pour les métadonnées, Zenodo propose en bas de la colonne de droite un encadré "Export" permettant de choisir le format (Dublin Core par exemple).

Files (894.7 MB)

Name	Size	
pb-ef1-neo_seq.fa md5:6d34cf2eb1934dd20125978791d92a1e ⓘ	7.0 kB	Download
pcr1_HEK293-GFP-PBwt.vs.hg19_pbneo.mem.bam md5:a71484141736b8db3d72dedb076c833 ⓘ	100.4 MB	Download
pcr2_HEK293-GFP-PBmut.vs.hg19_pbneo.mem.bam md5:dff0406a04096c08bad784e22de9f3e35 ⓘ	213.0 MB	Download
pcr3_HEK293-PGBD5-PBwt.vs.hg19_pbneo.mem.bam md5:37e485937532b2ab87cb543732273b4 ⓘ	143.4 MB	Download
pcr4_HEK293-PGBD5-PBmut.vs.hg19_pbneo.mem.bam md5:b17839a5002f5d81cd2d4556885bd2c2 ⓘ	437.7 MB	Download
summary_insertion_sites_pub.xlsx md5:64c0c7ab20304be5f1a1cc9d478b6cf ⓘ	70.5 kB	Download

Citation

Henssen, A. G., Henaff, E., Jiang, E., Eisenberg, A. R., Carson, J. R., Villasante, C. M., Ray, M., Still, E., Burns, M., Gandara, J., Feschotte, C., Mason, C. E., & Kentsis, A. (2015). Data from: Genomic DNA transposition induced by human PGBD5 [Data set]. Zenodo. <https://doi.org/10.5061/dryad.b2hc1>

Style: APA

Export

JSON

Résultat de l'exportation en format Dublin Core (un fichier XML) :

This XML file does not appear to have any style information associated with it. The document tree is shown below.

3. Métadonnées du dataset (Norme Dublin Core)

Les fichiers BAM contenus dans ce dataset représentent des reads mappés au génome humain hg19 avec des insertions de transposons.

Voici l'organisation structurée des informations récupérées pour le dataset choisi :

Élément Dublin Core	Valeur extraite
Title	Data from: Genomic DNA transposition induced by human PGBD5
Creator	Henssen, Anton G & Henaff, Elizabeth & Jiang, Eileen & Eisenberg, Amy R. & Carson, Julianne R. & Villasante, Camila M. & Ray, Mondira & Still,

	Eric & Burns, Melissa & Gandara, Jorge & Feschotte, Cedric & Mason, Christopher E. & Kentsis, Alex
Date	2015-09-28
Identifier (DOI)	https://doi.org/10.5061/dryad.b2hc1
Publisher	Zenodo
Description	Données de séquençage sur l'activité de transposition de l'élément PGBD5 dans les cellules HEK293 humaines.
Subject	Recombination, Genome remodeling, DNA transposition, Homo Sapiens

On a téléchargé et extrait les données du dataset Zenodo, on utilise Biopython pour analyser les insertions de transposons et Identifie les gènes affectés par ces insertions, après Génère des visualisations des hotspots d'insertion, puis fournit une analyse statistique des résultats :

Partie 3 :APPLICATION PRATIQUE : ANALYSE BIOINFORMATIQUE

AVEC BIOPYTHON

On va Démontrer concrètement l'utilité des données récupérées de Zenodo en réalisant une analyse bioinformatique avec Biopython. Cette partie illustre comment exploiter activement un dataset plutôt que de se contenter de le télécharger passivement.

À partir des métadonnées Dublin Core extraites du dataset sur la transposition ADN induite par PGBD5, j'ai développé un pipeline d'analyse Python/Biopython pour :

1. **Analyser automatiquement** les métadonnées XML
2. **Modéliser et étudier** les séquences de transposons
3. **Réaliser des analyses comparatives** entre différents éléments transposables
4. **Simuler des recherches** dans les bases de données publiques (NCBI)
5. **Générer un rapport scientifique** automatisé des résultats

Fonctionnalités principales implémentées :

Module	Fonctionnalité	Utilité scientifique
Analyse XML	Parsing des métadonnées Dublin Core	Extraction structurée des informations
Biopython Core	Manipulation de séquences ADN	Étude des propriétés des transposons
Alignements	Calculs de similarité	Analyse évolutive comparative
Entrez API	Recherche NCBI	Contexte bibliographique
Visualisation	Graphiques et matrices	Communication des résultats

Le code Python/Biopython développé pour cette analyse. Il est entièrement reproductible et documenté (`analyse_metadonnees_zenodo.py` & `main.py`) sur GitHub, en suivant le lien :

https://github.com/Warda-belmehboul/Projet-Biopython-et-Zenodo/blob/main/analyse_metadonnees_zenodo.py

<https://github.com/Warda-belmehboul/Projet-Biopython-et-Zenodo/blob/main/main.py>

Voici une partie du résultat obtenu après l'exécution du code Biopython

```

=====
RAPPORT D'ANALYSE COMPLET
Dataset: Genomic DNA transposition induced by human PGBD5
DOI: https://doi.org/10.5061/dryad.b2hc1
=====

1. MÉTADONNÉES DUBLIN CORE
-----
2. ANALYSE AVEC BIOPYTHON
-----
3. ANALYSE COMPARATIVE
-----
4. CONTEXTE SCIENTIFIQUE
-----
5. ANALYSE D'HOMOLOGIE
-----
CONCLUSION
=====


Cette analyse démontre l'utilisation intégrée de Zenodo et Biopython pour :

1. Extraction et analyse des métadonnées
2. Manipulation de séquences biologiques
3. Analyses comparatives
4. Intégration avec les bases de données publiques

Applications potentielles :
- Étude des sites d'insertion

```

In 1 Col 1 1173 caractères Toute la ligne



La création du compte GitHub :



Sign in to GitHub

Username or email address

Password [Forgot password?](#)

Sign in

or

 Continue with Google

 Continue with Apple

Création d'un nouvel entrepôt :

The screenshot shows the GitHub Home page. At the top left, there's a 'Dashboard' icon and a user profile icon. The top right features a search bar ('Type / to search'), a gear icon, and other navigation buttons. A red box highlights the 'Create repository' button in the top left corner of the main content area. To the right of the main content, there's a sidebar titled 'Latest from our changelog' with several items listed.

General

Owner *

Warda

Repository name *

Projet Biopython et Zenodo

Your new repository will be created as Projet-Biopython-et-Zenodo.

The repository name can only contain ASCII letters, digits, and the characters ., -, and -.

Great repository names are short and memorable. How about [vigilant-octo-disco](#)?

Description

Découvrir et analyser des outils couramment utilisés en sciences de la nature et de la vie ; • Comprendre les fo

240 / 550 characters

Configuration

Choose visibility *

Choose who can see and commit to this repository

Public

Projet-Biopython-et-Zenodo /

Drag additional files here to add them to your repository
Or choose your files

- analyse_metadonnees_zenodo.py
- requirements.txt
- main.py
- rapport Projet Biopython et Zenodo Détailé.docx
- rapport Projet Biopython et Zenodo Détailé.pdf

Commit changes

Add files via upload

Add an optional extended description...

Commit changes Cancel

This screenshot shows a GitHub repository named 'Projet-Biopython-et-Zenodo'. A red box highlights the repository path at the top. Below it is a large input field for dragging files, also with a red box around its placeholder text. A list of files is shown, each with a red circular icon and a delete 'x' button. A modal dialog titled 'Commit changes' is open, containing fields for adding files via upload and an optional description, both with red boxes around them. At the bottom of the dialog are 'Commit changes' and 'Cancel' buttons.

Après le dépôt du travail :

Projet-Biopython-et-Zenodo (Public)

Pin Watch

main 1 Branch 0 Tags Go to file Add file Code

Warda-belmehboul Add files via upload 138e0bb · now 1 Commit

- analyse_metadonnees_zenodo.py Add files via upload now
- main.py Add files via upload now
- rapport Projet Biopython et Zenodo Détailé.p... Add files via upload now
- requirements.txt Add files via upload now

README

This screenshot shows the same GitHub repository after the files have been committed. The repository name 'Projet-Biopython-et-Zenodo' is at the top, followed by 'Public' and 'Pin Watch' buttons. Below is a navigation bar with 'main', '1 Branch', '0 Tags', a search bar 'Go to file', an 'Add file' dropdown, and a 'Code' button. A commit history table shows one commit from 'Warda-belmehboul' with the message 'Add files via upload'. The commit hash is '138e0bb', it happened 'now', and there was '1 Commit'. Below the table is a 'README' section.